

1 Distribuciones discretas

Algunas de la más importantes variables aleatorias discretas, se listan a continuación:

1.1 Distribución de masa puntual

X tiene una distribución de masa puntual en a , $X \sim \delta_a$, si $\mathbb{P}(X = a) = 1$, en el caso que

$$F_X(x) = \begin{cases} 0 & x < a \\ 1 & x \geq a. \end{cases}$$

La función de masa de probabilidad es $p_X(x) = 1$ para $x = a$ y 0 en otros casos.

1.2 Distribución uniforme discreta

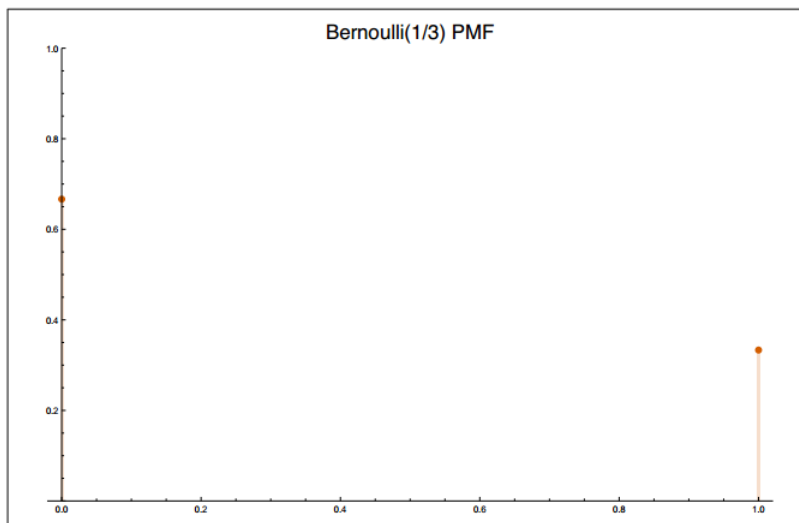
Sea $k > 1$ un número entero. Supongamos que X tiene PMF dado por

$$p_X(x) = \begin{cases} 1/k & \text{para } 1, \dots, k \\ 0 & \text{en otros casos.} \end{cases}$$

Decimos que X tiene una distribución uniforme sobre $\{1, \dots, k\}$.


1.3 Distribución de Bernoulli

Sea X que representa un lanzamiento de una moneda. Entonces $\mathbb{P}(X = 1) = p$ y $\mathbb{P}(X = 0) = 1 - p$ para algún $p \in [0, 1]$, entonces decimos que X tiene una distribución de Bernoulli, escrita como $X \sim \text{Bernoulli}(p)$. La función de probabilidad es $p_X(x) = p^x(1-p)^{1-x}$ para $x \in \{0, 1\}$.



La distribución de $\text{Bernoulli}(p)$ tiene una media:

$$\mathbb{E}(X) = \sum_{x=0,1} xp(X=x) = 0(1-p) + 1p = p.$$



Además:

$$\mathbb{E}(X)^2 = \sum_{x=0,1} x^2 p(X=x) = 0^2(1-p) + 1^2 p = p$$

y así la varianza:

$$\mathbb{V}(X) = \mathbb{E}(X^2) - [\mathbb{E}(X)]^2 = p - p^2 = p(1-p).$$

La varianza es maximizada para el valor de $p = 1/2$ y cada momento es el mismo $\mathbb{E}(X^\alpha) = 0^\alpha(1-p) + 1^\alpha p = p$.

1.4 Distribución binomial

Supongamos que tenemos una moneda, que cae cara con una probabilidad p para algún $0 \leq p \leq 1$. Lanzamos la moneda n veces y sea X el número de caras. Asumimos que estos lanzamientos son independientes. El PMF de X , $p_X(x) = \mathbb{P}(X=x)$ para esta distribución es:

$$p_X(x) = \begin{cases} \binom{n}{x} p^x (1-p)^{n-x} & \text{para } x = 0, \dots, n \\ 0 & \text{en otros casos.} \end{cases}$$



Esta es la suma de n variables aleatorias independientes de Bernoulli. Se denota como $X \sim \text{Binomial}(n, p)$.

Desde que la esperanza es un operador lineal, la esperanza de una distribución Binomial, es la suma de las esperanzas de las distribuciones de Bernoulli involucradas, así si X es una distribución Binomial(n, p):

$$\mathbb{E}(X) = np,$$

y desde que la varianza de la suma de variables independientes es la suma de varianzas,

$$\mathbb{V}(X) = np(1-p).$$



1.5 Distribución binomial negativa

Replicar un experimento de Bernoulli (p) de forma independiente hasta que ocurre el r -ésimo éxito ($r \geq 1$). Sea X el número de pruebas en el cual se produce el r -ésimo éxito. Entonces se dice que X tiene una distribución binomial negativa(r, p).

Existe otra definición de distribución binomial negativa, a saber, la distribución del número de fallos antes del r -ésimo éxito. (Esta es la definición empleada por R, en los cálculos).

La relación entre las dos definiciones es bastante simple. Si X es binomial negativo en el sentido usual y F es binomial negativo en el sentido de R, entonces:

$$F = X - r$$

¿Cuál es la probabilidad de que el r -ésimo éxito ocurre en la prueba t , para $t \geq r$?. Para que esto suceda, debe haber $t - r$ fracasos y $r - 1$ éxitos, en las primeras $t - 1$ pruebas, con un éxito en la prueba t .

Por independencia, esto sucede con la probabilidad binomial para $r - 1$ éxitos en las primeras $t - 1$ pruebas, por la probabilidad p de éxito en la prueba t :

$$P(X = t) = \binom{t-1}{r-1} p^r (1-p)^{t-r} \quad (t \geq r).$$

de esta manera la probabilidad es cero, cuando $t < r$. El caso especial $r = 1$ es llamada distribución geométrica. Es decir, X tiene una distribución geométrica con parámetro $p \in (0,1)$, denotada como

$X \sim \text{Geom}(p)$, si

$$\mathbb{P}(X = k) = p(1 - p)^{k-1}, \quad k \geq 1.$$

Tenemos a partir de este resultado que

$$\sum_{k=1}^{\infty} \mathbb{P}(X = k) = p \sum_{k=1}^{\infty} (1 - p)^k = \frac{p}{1 - (1 - p)} = 1.$$

X es el número de lanzamientos necesarios hasta que la primera cara salga, cuando una moneda es lanzada. La media de una distribución geométrica, tiene el valor de:

$$\mathbb{E}(X) = \sum_{t=1}^{\infty} tp(1 - p)^{t-1} = \frac{1}{p}.$$

Además que se tiene:

$$\mathbb{V}(X) = \mathbb{E}(X^2) - [\mathbb{E}(X)]^2 = \frac{1 - p}{p}.$$

La distribución binomial negativa(r, p) es la suma de r de variables aleatorias geométricas independientes $\text{Geom}(p)$. Como la esperanza es un operador lineal positivo, se concluye que la media de $\text{binomial negativa}(r, p)$ es r veces la media que $\text{Geom}(p)$ y la varianza de una suma independiente es la suma de varianzas, así:

Si $X \sim \text{binomial negativa}(r, p)$, entonces:

$$\mathbb{E}(X) = \frac{r}{p} \quad \text{y} \quad \mathbb{V}(X) = \frac{r(1 - p)}{p^2}.$$

1.6 Distribución multinomial

En un sentido, la distribución multinomial generaliza la distribución binomial a experimentos aleatorios independientes con más de dos resultados. Es la distribución de un vector que cuenta cuántas veces se produce cada resultado. Se denota como $X \sim \text{Multinomial}(n, \mathbf{p})$.

Un vector aleatorio multinomial es un m -vector \mathbf{X} de resultados en una secuencia de n repeticiones independientes de un experimento aleatorio con m resultados distintos.

Si el experimento tiene m resultados posibles y el i -ésimo resultado tiene probabilidad p_i , entonces la función de masa de probabilidad $\text{Multinomial}(n, \mathbf{p})$ viene dada por:

$$\mathbb{P}(\mathbf{X} = (k_1, \dots, k_m)) = \frac{n!}{k_1! k_2! \dots k_m!} p_1^{k_1} \cdot p_2^{k_2} \dots p_m^{k_m}.$$

donde $k_1 + k_2 + \dots + k_m = n$.

Si contamos el resultado k como éxito, entonces es obvio que cada X_k es simplemente una variable aleatoria binomial (n, p_k) . Pero los componentes no son independientes, ya que suman a n .

1.7 Distribución de Rademacher

La distribución $\text{Rademacher}(p)$ es una grabación de la distribución de Bernoulli, 1 todavía indica éxito, pero el fracaso se codifica como -1 . Si Y es una variable aleatoria $\text{Bernoulli}(p)$, entonces $X = 2Y - 1$ es una variable aleatoria $\text{Rademacher}(p)$. La función de masa de probabilidad es:

$$\mathbb{P}(X = x) = \begin{cases} p & x = 1 \\ 1 - p & x = -1 \end{cases}$$

Una variable aleatoria X Rademacher(p) tiene una media:

$$\mathbb{E}(X) = \sum_{x=-1,1} xp(X=x) = -1(1-p) + 1p = 2p-1.$$

Además $X^2 = 1$, así:

$$\mathbb{E}(X^2) = 1,$$

por tanto la varianza es:

$$\mathbb{V}(X) = \mathbb{E}(X^2) - [\mathbb{E}(X)]^2 = 1 - (2p-1)^2 = 4p(1-p).$$

Una secuencia de sucesivas sumas de variables aleatoria independientes de Rademacher(p) es llamado **camino aleatorio**. Esto es, si X_i son idénticamente distribuidas a variables aleatorias Rademacher($1/2$), la secuencia S_1, S_2, \dots es un camino aleatorio, donde:

$$S_n = X_1 + \dots + X_n.$$

Desde que el operador esperanza es un operador lineal:

$$\mathbb{E}(S_n) = 0, \text{ para todo } n,$$

y desde que la varianza de la suma de variables aleatorias independientes es la suma de varianzas:

$$\mathbb{V}(S_n) = n, \text{ para todo } n.$$

1.8 Distribución de Poisson

Una variable aleatoria de Poisson N modela el recuento de éxitos cuando la probabilidad de éxitos es pequeña y el número de pruebas independientes es grande, de modo que la tasa de éxito promedio μ . Se denota esta variable aleatoria como $X \sim \text{Poisson}(\mu)$ si:

$$\mathbb{P}(N=k) = e^{-\mu} \frac{\mu^k}{k!} \quad k=0,1,\dots$$

Así :

$$\mathbb{E}(N) = \mu \text{ y } \mathbb{V}(N) = \mu.$$

La distribución de Poisson es usado a menudo como un modelo para eventos, como decaimiento radiactivo y accidentes de tráfico.



Ladislaus von Bortkiewicz se refirió a la distribución de Poisson como La Ley de los números pequeños. Se puede pensar esto, como un límite peculiar de las distribuciones binomiales. Consideremos una secuencia de variables binomiales(n, p), donde la probabilidad p de éxito va a cero, pero el número n de pruebas crece de tal manera que $np = \mu$ permanece fijo. Entonces tenemos la siguiente proposición:

Proposición 1.1 Para cada k :

$$\lim_{n \rightarrow \infty} \text{Binomial}(n, \mu/k)(k) = \text{Poisson}(\mu)(k).$$

2 Distribuciones continuas

Algunas de la más importantes variables aleatorias continuas, se listan a continuación:



2.1 La familia Normal

De acuerdo con el teorema del límite central, la distribución limitante de la suma estandarizada un gran número de variables aleatorias independientes, es la distribución normal.

La densidad de $N(\mu, \sigma^2)$ es:

$$f_{\mu, \sigma^2}(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

La media de una variable aleatoria $N(\mu, \sigma^2)$ es:

$$\mathbb{E}(X) = \mu$$

y la varianza es:

$$\mathbb{V}(X) = \sigma^2.$$

La distribución normal estándar tiene media $\mu = 0$ y $\sigma^2 = 1$, así la función densidad:

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}.$$

La media es: $\mathbb{E}(X) = 0$ y la varianza $\mathbb{V}(X) = 1$.

El CDF de esta variable aleatoria, se denota como Φ y se define como:

$$\Phi(t) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^t e^{-\frac{x^2}{2}} dx.$$


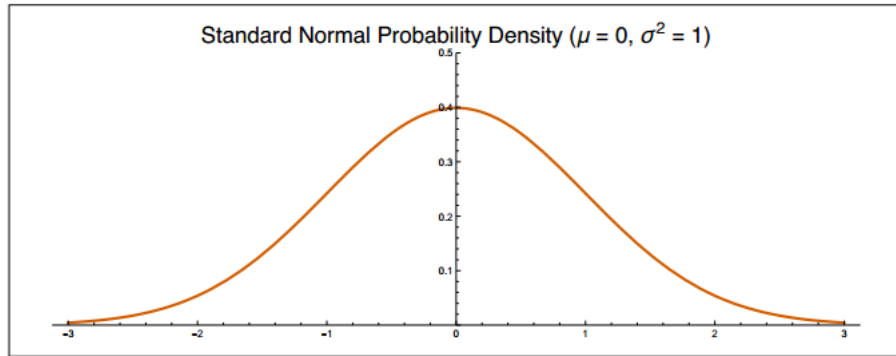
(Familia Normal) Si Z es una variable normal estándar, entonces:

$$\sigma Z + \mu \sim N(\mu, \sigma^2)$$

y si

$$X \sim N(\mu, \sigma^2), \text{ entonces } \frac{x - \mu}{\sigma} \sim N(0, 1)$$

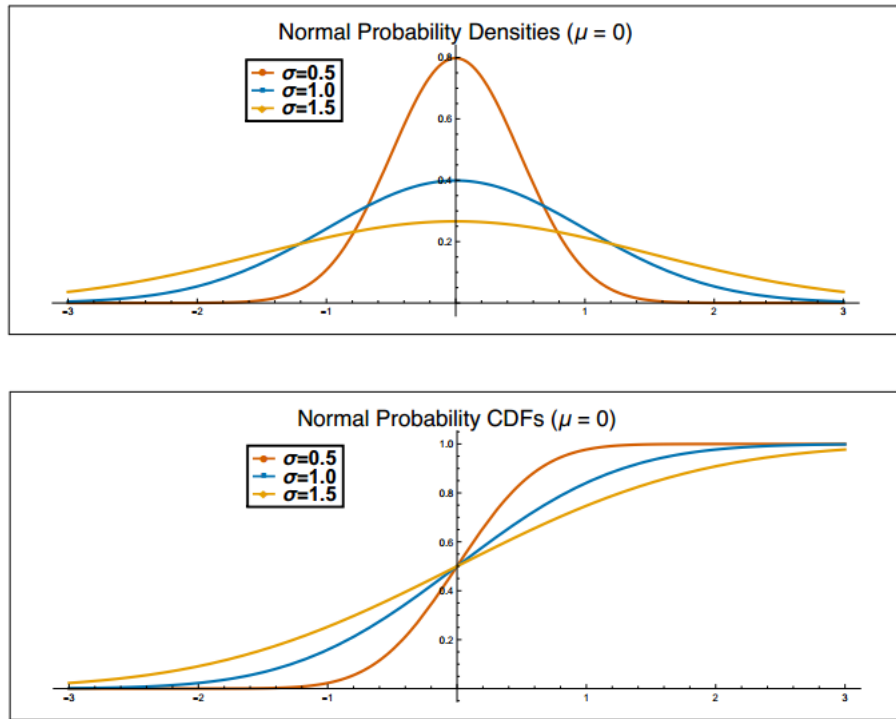
Si X y Z son normales e independientes, entonces $aX + bZ$ es también normal.



2.2 La familia Exponencial

La familia Exponencial se usa para modelar tiempos de espera. Una variable aleatoria exponencial Exponencial (λ) tiene una densidad:

$$f(t) = \lambda e^{-\lambda t}$$



y un CDF:

$$F(t) = 1 - e^{-\lambda t}.$$

Si definimos la función (Survival function):

$$G(t) = 1 - F(t) = e^{-\lambda t}.$$

Entonces la tasa de Hazard $f(t)/G(t)$ es igual a λ .

La media de la Exponencial (λ) es:

$$\mathbb{E}(T) = \frac{1}{\lambda}$$

y la varianza es:

$$\mathbb{V}(T) = \frac{1}{\lambda^2}.$$

La familia Exponencial tiene la **Propiedad de Markov** o memoryless:



$$\mathbb{P}(T < t + s | T > t) = \mathbb{P}(T > s).$$

2.3 La familia Gamma

La familia de distribuciones $\text{Gamma}(r, \lambda)$ es versátil. La distribución de la suma de r variables aleatorias Exponencial(λ) independientes, la distribución del r -ésimo tiempo de llegada en un proceso de Poisson con tasa de llegada λ es la distribución $\text{Gamma}(r, \lambda)$.

La distribución de la suma de cuadrados de n distribuciones normales estándar independientes, la distribución $\chi^2(n)$ es la distribución $\text{Gamma}(1/2, 1/2)$.

La distribución $\text{Gamma}(r, \lambda)$ en general ($r > 0, \lambda > 0$), tiene una densidad dado por:



$$f(t) = \frac{\lambda^r}{\Gamma(r)} t^{r-1} e^{-\lambda t} \quad (t > 0).$$

La media y la varianza de un variable aleatoria Gamma(r , λ) es dado por:

$$\mathbb{E}(X) = \frac{r}{\lambda} \quad \mathbb{V}(X) = \frac{r}{\lambda^2}.$$



2.4 Distribución de Cauchy

Si X e Y son normales estándar independientes, entonces Y/X tiene una distribución de Cauchy. La distribución de Cauchy, es la distribución de la tangente de un ángulo aleatoriamente seleccionado desde $[-\pi, \pi]$.

La densidad es:

$$f(x) = \frac{1}{\pi(1+x^2)},$$

y el CDF:





$$F(t) = \frac{1}{\pi} \arctan(t) + \frac{1}{2}.$$

$$\begin{aligned} \int_{-\infty}^{\infty} f(x) dx &= \frac{1}{\pi} \int_{-\infty}^{\infty} \frac{dx}{(1+x^2)} = \frac{1}{\pi} \int_{-\infty}^{\infty} \frac{d \tan^{-1}(x)}{dx} \\ &= \frac{1}{\pi} [\tan^{-1}(\infty) - \tan^{-1}(-\infty)] = \frac{1}{\pi} \left[\frac{\pi}{2} - \left(-\frac{\pi}{2} \right) \right] = 1. \end{aligned}$$

La esperanza de una distribución de Cauchy no existe :

$$\begin{aligned} \int_0^t \frac{x}{\pi(1+x^2)} dx &= \frac{\ln(1+t^2)}{2\pi} \rightarrow \infty \text{ si } t \rightarrow \infty. \\ \int_{-t}^0 \frac{x}{\pi(1+x^2)} dx &= \frac{-\ln(1+t^2)}{2\pi} \rightarrow -\infty \text{ si } t \rightarrow \infty. \end{aligned}$$



Así



$$\int_{-\infty}^{\infty} \frac{x}{\pi(1+x^2)} dx \text{ es divergente y sin sentido.}$$

2.5 Distribución uniforme

Una variable aleatoria continua X que es igualmente probable que tome cualquier valor en un rango de valores (a, b) , con $a < b$, da lugar a la distribución uniforme. Dicha distribución está uniformemente distribuida en su rango. Algunas veces se denota como $X \sim \text{Uniforme}(a, b)$.

La función densidad de la distribución es:

$$f(x) = \begin{cases} \frac{1}{b-a} & x \in [a, b] \\ 0 & \text{en otros casos.} \end{cases}$$





El CDF es:

$$F(x) = \begin{cases} \frac{x-a}{b-a} & x \in [a, b] \\ 0 & \text{en otros casos.} \end{cases}$$

La media y la varianza de la variable aleatoria uniforme es:

$$\mathbb{E}(X) = \frac{a+b}{2} \quad \mathbb{V}(X) = \frac{(b-a)^2}{12}.$$







2.6 Distribución beta


X tiene una distribución Beta con parámetros $\alpha > 0$ y $\beta > 0$, denotado por $X \sim \text{Beta}(\alpha, \beta)$, si

$$f(x) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1}, \quad 0 < x < 1.$$

La media y la varianza de una distribución Beta es:

$$\mathbb{E}(X) = \frac{\alpha}{\alpha + \beta} \quad \mathbb{V}(X) = \frac{\alpha\beta}{(\alpha + \beta)^2(1 + \alpha + \beta)}.$$





2.7 La distribución $\chi^2(n)$

Sea Z_1, \dots, Z_n variables aleatorias normales estándar. La distribución Chi-cuadrado con n grados de libertad, $\chi^2(n)$ es la distribución de:

$$R_n^2 = Z_1^2 + \dots + Z_n^2.$$

La función densidad de esta distribución, está dado por:


$$f_{R_n^2}(t) = \frac{1}{2^{n/2}\Gamma(n/2)} t^{(n/2)-1} e^{-t/2}, \quad (t > 0),$$

y escribimos:

$$R_n^2 \sim \chi^2(n).$$

La media y varianza son caracterizadas por:

$$\mathbb{E}(R_n^2) = n, \quad \mathbb{V}(R_n^2) = 2n.$$

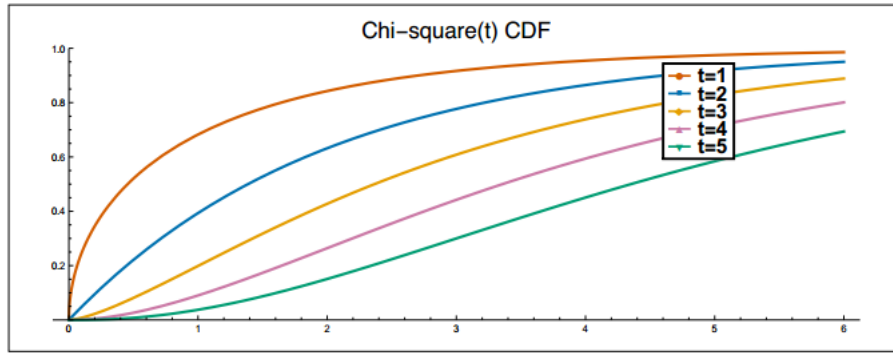


Se sigue de la definición que si X e Y son independientes y $X \sim \chi^2(n)$ y $Y \sim \chi^2(m)$, entonces:

$$(X + Y) \sim \chi^2(n + m).$$

Esta es una distribución importante en estadística inferencial y es la base de la prueba de ajustes chi-cuadrado y el método de estimación de mínimos de chi-cuadrado.

Si hay m resultados posibles de un experimento y sea p_i la probabilidad de que el resultado i ocurre. Si el experimento se repite independientemente N veces, sea N_i el número de veces que se observa el resultado i , por lo que $N = N_1 + \dots + N_m$. Entonces la estadística del chi-cuadrado:



$$\sum_{i=1}^n \frac{(N_i - Np_i)^2}{Np_i},$$

converge en distribución cuando $N \rightarrow \infty$ a una distribución $\chi^2(m-1)$ con $m-1$ grados de libertad.